

Lista #3 – Inteligência Artificial

Análise de Sobrevivência dos Passageiros do Titanic

Matheus de Almeida Moreira

Matrícula: 848813

Curso: Ciência da Computação – PUC Minas

20 de setembro de 2026

Disciplina: Inteligência Artificial

Professora: Cristiane Neri Nobre

Questão 01

1 Pré-processamento

1.1 a) Imputação de dados ausentes

Para lidar com os valores ausentes na base de dados, foram comparados dois métodos de imputação: **KNN Imputer** ($k = 5$) e **MissForest** (imputação iterativa baseada em árvores).

A Tabela 1 e a Figura 1 apresentam a comparação do atributo **Age** antes e depois da imputação para cada método.

Tabela 1: Comparação entre os métodos de imputação para o atributo Age.

Método	Média observada	Média após imputação	Desvio padrão	Efeito na distribuição
KNN Imputer	29.60	30.05	14.51	Preservou melhor as distribuições marginais numéricas
MissForest (RF)	29.60	29.52	13.40	Redução na dispersão (menor desvio padrão)




Figura 1: Comparação da distribuição dos dados antes e depois da imputação.

A partir da comparação visual e do cálculo da distância de Wasserstein, observou-se que o **KNN Imputer** apresentou maior preservação das distribuições originais numéricas. Apesar disso, **ambos** os métodos foram mantidos e explorados nas etapas seguintes para avaliar o impacto do método no desempenho preditivo final, sendo o MissForest escolhido como principal na melhor configuração devido à qualidade preditiva conjunta na validação.

1.2 b) Balanceamento de classes

Inicialmente, analisou-se a distribuição da variável **Survived**. O conjunto de treino apresentou desbalanceamento com 647 registros para Não Sobreviventes e 400 registros para Sobreviventes.

Para lidar com esse desbalanceamento (aplicado exclusivamente ao conjunto de treino), foram testadas duas técnicas: **SMOTE** e **Random Under Sampling**. A distribuição das classes antes e depois do balanceamento é apresentada na Tabela 2 e ilustrada na Figura 2.

Tabela 2: Distribuição das classes antes e depois do balanceamento.

Conjunto	Classe 0 (Não sobreviveu)	Classe 1 (Sobreviveu)
Treino original	647	400
SMOTE	647	647
Random Under Sampling	400	400




Figura 2: Distribuição das classes no conjunto de treino com as técnicas de balanceamento.

2 Modelagem com Árvore de Decisão

2.1 a) Treinamento

Foi utilizado o estimador `DecisionTreeClassifier` do `scikit-learn` para prever a sobrevivência dos passageiros.

2.2 b) e c) Otimização de Hiperparâmetros

A otimização dos hiperparâmetros (`max_depth`, `min_samples_split`, `min_samples_leaf`, `criterion`) foi conduzida com dois otimizadores: **Randomized Search** e **Otimização Bayesiana (Optuna TPE)**. Os resultados podem ser visualizados na Tabela 3.

Tabela 3: Melhores hiperparâmetros e tempo de execução – Árvore de Decisão.

Otimizador	Melhores hiperparâmetros	Melhor score CV	Tempo (s)
Randomized Search	<code>min_samples_split=10, min_samples_leaf=5, max_depth=4, criterion=gini</code>	0.737	4.67
Optuna (Bayesiano)	<code>min_samples_split=10, min_samples_leaf=5, max_depth=4, criterion=gini</code>	0.737	4.69

2.3 d) Regras obtidas pela árvore de decisão

A árvore otimizada extraída apresentou as seguintes regras, ilustrando de forma legível o padrão de sobrevivência e mortalidade:

```
|--- sex_female <= 0.003
|   |--- age <= 9.492
|   |   |--- sibsp <= 2.500
|   |   |   |--- pclass <= 2.829
|   |   |   |   |--- weights: [0.0, 16.0] class: 1
|   |   |   |   |--- pclass > 2.829
|   |   |   |   |--- weights: [5.0, 16.0] class: 1
```

```

| | | |--- sibsp > 2.500
| | | | |--- age <= 3.500
| | | | | |--- weights: [5.0, 1.0] class: 0
| | | | |--- age > 3.500
| | | | | |--- weights: [10.0, 0.0] class: 0
| | |--- age > 9.492
| | | |--- pclass <= 1.500
| | | | |--- age <= 45.498
| | | | | |--- weights: [49.0, 57.0] class: 1
| | | | |--- age > 45.498
| | | | | |--- weights: [43.0, 13.0] class: 0
| | |--- pclass > 1.500
| | | |--- weights: [431.0, 90.0] class: 0
|--- sex_female > 0.003
| |--- pclass <= 2.985
| | |--- fare <= 26.024
| | | |--- weights: [12.0, 87.0] class: 1
| | |--- fare > 26.024
| | | |--- weights: [3.0, 223.0] class: 1
| |--- pclass > 2.985
| | |--- fare <= 23.350
| | | |--- weights: [68.0, 141.0] class: 1
| | |--- fare > 23.350
| | | |--- weights: [21.0, 3.0] class: 0

```




Figura 3: Representação visual (primeiros níveis) da melhor Árvore de Decisão gerada.

3 Modelagem com Random Forest

3.1 a) Treinamento

O `RandomForestClassifier` foi treinado com o intuito de testar um método ensemble para a base, onde múltiplas árvores de decisão são geradas e agrupadas por votação majoritária.

3.2 b) e c) Otimização de Hiperparâmetros

Os hiperparâmetros (`n_estimators`, `max_depth`, `min_samples_split`, `max_features`, `criterion`) foram otimizados utilizando os mesmos métodos (Random Search e Optuna) para possibilitar a comparação justa. A Tabela 4 apresenta os melhores parâmetros encontrados e seus respectivos tempos de execução.

Tabela 4: Melhores hiperparâmetros e tempo de execução – Random Forest.

Otimizador	Melhores hiperparâmetros	Melhor score CV	Tempo (s)
Randomized Search	<code>n_est=200, max_depth=None, min_samples=10, max_features=sqrt, entropy</code>	0.743	7.56
Optuna (Bayesiano)	<code>n_est=80, max_depth=8, min_samples=2, max_features=sqrt, gini</code>	0.753	7.26

4 Avaliação e comparação dos resultados

4.1 a) Métricas de Classificação

A Tabela 5 consolida a acurácia, precisão, recall e F1-score no conjunto de teste para as combinações de imputação, balanceamento e modelo.

Tabela 5: Comparação de desempenho das diferentes configurações (Conjunto de Teste).

Modelo	Imputação	Balanceamento	Acurácia	Precisão	Recall	F1
Decision Tree	KNN	SMOTE	0.824	0.745	0.820	0.781
Decision Tree	KNN	UnderSampling	0.840	0.815	0.750	0.781
Decision Tree	MissForest	SMOTE	0.813	0.726	0.820	0.770
Decision Tree	MissForest	UnderSampling	0.832	0.798	0.750	0.773
Random Forest	KNN	SMOTE	0.828	0.767	0.790	0.778
Random Forest	KNN	UnderSampling	0.828	0.757	0.810	0.783
Random Forest	MissForest	SMOTE	0.836	0.771	0.810	0.790
Random Forest	MissForest	UnderSampling	0.824	0.760	0.790	0.775

4.2 b) Árvore de Decisão vs. Random Forest

O melhor **Random Forest** (com MissForest, SMOTE e Optuna) apresentou F1-score de **0.790** e acurácia de **0.836**. Já a melhor Árvore de Decisão alcançou F1-score de **0.781** e acurácia de **0.840**. O Random Forest tende a **generalizar melhor** porque combina

diversas árvores em vez de depender de apenas uma, resultando em um maior equilíbrio de classificação refletido no F1-score.

4.3 c) Otimizadores de Hiperparâmetros

A Otimização Bayesiana (Optuna) e o Randomized Search produziram configurações de hiperparâmetros significativamente diferentes. A Otimização Bayesiana alcançou as métricas levemente superiores no treinamento (Validação Cruzada), e quanto à **eficiência**, o **Optuna (Bayesiano)** foi melhor, alcançando um score superior com um tempo ligeiramente inferior para a floresta (7.26s vs 7.56s da busca aleatória).

4.4 d) Métodos de Imputação

O **KNN Imputer** preservou melhor a distribuição marginal numérica dos dados (verificável visualmente e pela distância de Wasserstein calculada). Contudo, a diferença média de F1-score observada no teste foi muito pequena (aproximadamente 0.002), indicando que **não houve impacto expressivo** entre os métodos sobre a qualidade das previsões.

4.5 e) Técnicas de Balanceamento

O método **SMOTE** produziu o melhor equilíbrio para a classe minoritária. O Random Under Sampling forneceu alta precisão, mas com prejuízo no recall (aumentando falsos negativos). O SMOTE, ao interpolar instâncias sintéticas minoritárias sem descartar amostras da classe majoritária, garantiu médias mais equilibradas entre a identificação dos sobreviventes (recall) e a taxa de acerto nas predições positivas (precisão).

4.6 f) Regras e Interpretabilidade

As regras descritivas da Árvore de Decisão mostraram claramente as associações: passageiros masculinos raramente sobreviviam (a não ser crianças nas classes 1 e 2), enquanto mulheres de classes superiores sobreviviam com frequência quase total.

Contudo, essas regras **não se mantêm interpretáveis da mesma forma no Random Forest**. Uma Random Forest opera por agregação e voto de dezenas ou centenas de árvores independentes geradas com características amostrais diferentes. Sendo assim, o **Random Forest tende a apresentar melhor desempenho preditivo** por combater a variância e o overfitting de árvores únicas, mas **perde a interpretabilidade clara**, visto que não se tem mais um único caminho direto e simples para explicar as decisões do conjunto.

Conclusão: A reestruturação completa da modelagem expõe a relevância de cada etapa. Observou-se a predominância do Random Forest auxiliado pelo SMOTE para tratamento de dados desbalanceados. A Otimização Bayesiana evidenciou sua capacidade de convergir em pontos ótimos mais adequados se comparado ao método randômico, e, por fim, demonstrou-se na prática o conhecido viés entre a clareza e transparência de

uma única Árvore de Decisão em detrimento do poder preditivo de um modelo ensemble (Random Forest) com baixa interpretabilidade.